

摘 要

随着人工智能的快速发展，其在医疗领域的应用前景愈发广阔，各种机器学习和深度学习技术被广泛应用于临床辅助。然而，医疗 AI 模型具有典型的黑盒特点，其决策背后缺乏清晰的理论支撑。依赖无法解释的黑盒系统做出决策可能导致临床诊疗的盲目性，甚至危及生命。可解释人工智能（Explainable AI, XAI）在促进人类对深度学习系统的理解和信任方面发挥着至关重要的作用，对于避免或最大限度地减少 AI 模型错误的负面影响具有重要意义，已经成为人工智能领域的重要研究方向，也是医疗 AI 技术及应用落地部署的重要前提。

相对于其他行业，医疗领域由于与人类生命和疾病诊疗密切相关，其对可解释人工智能相关的理论、技术和方法均提出了更高要求。尽管可解释医疗 AI 在近年来受到了极大关注，但已有研究仍然属于传统 XAI 方法在医疗领域的应用，难以适应具有较强专业性约束的临床辅助场景，尚不能支撑医疗 AI 的普遍应用和部署，并且在可解释技术和方法的可靠性、可用性、易用性和好用性等方面均与临床要求存在较大差距，无法解决医生和患者迫切希望得到的“是什么？为什么？”的问题。针对此问题，本论文重点开展了如下几个方面的工作：

（1）面向医疗 AI 实际部署和临床辅助需求，提出了医疗 AI 可解释性研究的三阶段分类方法，将可解释医疗 AI 研究分为数据可解释、过程可解释以及结果可解释三个阶段，明确了各阶段研究目标和覆盖范围，并给出了结果可解释定义和度量指标，进而为可解释医疗 AI 的研究与应用提供了新的技术思路。

（2）针对医疗 AI 模型训练数据不均衡问题，研究了具有可解释性的数据处理技术，提出了基于反事实的医疗数据增强方法，解决了传统数据增强缺乏依据和可解释性导致的新生成数据冗余和不可信问题，提升了医疗 AI 的临床泛化能力，提高了算法精度和准确性。同时，以糖尿病预测为临床应用背景，对相关方法进行了测试和验证。

（3）针对医疗 AI 的结果可解释性，设计了基于大语言模型和智能体的结果可解释系统架构，提出了自然语言形式的知识三元组转换、知识重排以及多 Issue 比对的覆盖度计算等关键算法，并针对一种血液罕见病淀粉样变性的风险预测进行了临床应用实现，验证了结果可解释相关技术和方法。

（4）针对基于大语言模型实现结果可解释方法存在的大语言模型不专业等问题，提出了大语言模型系统工程概念，定义了大语言模型系统工程体系框架，并围绕血液罕