

第1章 绪论

随着人工智能（Artificial Intelligence, AI）技术的飞速发展，其在医疗领域的应用前景愈发广阔，各种机器学习（Machine Learning, ML）^{[1]-[3]}技术被广泛应用于不同的医疗场景，特别是基于深度学习（Deep Learning, DL）的方法为各种诊疗任务提供了更高质量的性能保障，包括：医学图像重建、电子健康记录管理、癌症诊断、疾病预测、医学影像分析、图像检索和计算生物学等^{[4]-[17]}。深度学习模型由多层神经元组成并通过非线性激活函数实现彼此连接，网络结构复杂，与传统的机器学习相比，泛化能力更强，结果更加准确。然而，无论是机器学习模型还是深度学习模型，均具有典型的黑盒（Black Box）特点，其决策背后缺乏清晰的理论支撑^[18]。依赖无法解释的黑盒系统做出决策将导致临床诊疗的盲目性^[19]。因此，尽管基于 DL 的医疗应用比 ML 系统具有更显著的性能表现，但要建立医生和患者对这些医疗 AI 应用的信任仍然面临巨大挑战。为了尽早发挥人工智能技术的先进性和有效性，提高临床工作效率和质量，实现医疗 AI 的决策能够以人类可理解的方式进行解释和说明就具有相当的必要性和紧迫性。

可解释人工智能（Explainable AI, XAI）在促进人类对深度学习系统的理解和信任方面发挥着至关重要的作用^[20-22]。当前，随着算力基础设施的普及，AI 模型越来越无处不在，越来越渗透到日常生活的方方面面。可解释性对于避免或最大限度地减少模型错误的负面影响是非常必要的，已经成为人工智能领域的重要研究方向，也是 AI 在医疗等专业性约束极为严格的领域中大范围推广应用的难点问题。

相对于其他行业，医疗领域由于与人类生命和疾病诊疗救治过程密切相关，其对可解释人工智能相关的理论、技术和方法均提出了更高要求，在临床疾病早期风险预警、辅助诊断和个性化治疗等实际应用中，也面临着更多的约束和限制，输入和输出结果的责任、信任和可解释性问题日益突出^[23]。

本论文面向人工智能的实际应用需求，重点开展面向临床辅助的医疗 AI 可解释性研究，探索可解释的医疗 AI 应用系统实现路径。

本章将从以下几个方面阐述论文工作的出发点和研究思路。首先，阐述可解释 AI 以及可解释医疗 AI 的研究背景及意义；其次，分析医疗 AI 可解释性研究的现状及其面临的问题和挑战；最后，对本论文的研究方向、研究思路及主要内容进行概括并给出全文的逻辑结构。